Université Ibn Zohr
Ecole nationale des sciences appliquées à Agadir

A.U. 2024-2025
SDBDIA
Semestre 2

Python Avancé

TP 4 (Atelier)

1. Installation

```
pip install beautifulsoup4 requests
```

2. Exemples de Base

Exemple 1 : Lire le titre d'une page

Changer l'url par un url valide comme(https ://www.wikipedia.org)

```
from bs4 import BeautifulSoup
import requests

url = "https://exemple.com"
page = requests.get(url)
soup = BeautifulSoup(page.text, 'html.parser')

print("Titre de la page:", soup.title.text)
```

Exemple 2 : Trouver tous les liens

```
for link in soup.find_all('a'):
    print("Lien:", link.get('href'))
```

Exemple 3 : Extraire tous les paragraphes

```
for p in soup.find_all('p'):
    print("Paragraphe:", p.text)
```

Exemple 4 : Récupérer le contenu d'une balise spécifique

```
titre_principal = soup.find('h1')
if titre_principal:
    print("Titre principal:", titre_principal.text)
```

Exemple 5 : Trouver tous les liens internes

```
for link in soup.find_all('a'):
    href = link.get('href')
    if href and href.startswith('/'):
        print("Lien interne:", href)
```

Exemple 6 : Obtenir les attributs d'une image

```
for img in soup.find_all('img'):
    print("Source:", img.get('src'))
    print("Texte alternatif:", img.get('alt'))
```

Exemple 7 : Extraire le texte brut de la page

```
print("Texte brut de la page:\n", soup.get_text())
```

Exemple 8 : Extraire tous les titres (balises h1 à h6)

```
for i in range(1, 7):
    for tag in soup.find_all(f'h{i}'):
        print(f"Titre h{i} :", tag.text)
```

Exemple 9 : Extraire les liens vers les réseaux sociaux (contenant 'facebook', 'twitter', etc.)

use : https ://webscraper.io/test-sites

```
reseaux = ['facebook', 'twitter', 'linkedin', 'instagram']
for link in soup.find_all('a', href=True):
    if any(reseau in link['href'] for reseau in reseaux):
        print("Lien réseau social:", link['href'])
```

Exemple 10 : Extraire les commentaires HTML de la page

```
from bs4 import Comment

for comment in soup.find_all(string=lambda text: isinstance(text,
   Comment)):
    print("Commentaire HTML:", comment)
```

3. Exemples avec Sélecteurs

Exemple 11 : Trouver par classe CSS

```
articles = soup.find_all('div', class_='article')
for article in articles:
    print("Article:", article.text[:50])
```

Exemple 12 : Trouver par ID

vous changer id selon les id qui se trouvent dans le site. (exemple id='js-link-box-pl' pour le site de https ://www.wikipedia.org)

```
header = soup.find(id='header')
print("En-tête:", header.text)
```

Exemple 13 : Sélection CSS avancée

```
menu_links = soup.select('div.menu a')
for link in menu_links:
    print("Lien menu:", link['href'])
```

Exemple 14 : Sélectionner des éléments avec plusieurs classes CSS

```
elements = soup.select('div.class1')
for element in elements:
    print("Élément avec plusieurs classes:", element.text)
```

Exemple 15 : Sélectionner un élément avec un attribut spécifique

```
images = soup.select('img[src]')
for img in images:
    print("Image avec attribut src:", img['src'])
```

Exemple 16 : Sélectionner un enfant spécifique dans un élément parent

```
parent = soup.find('div', class_='parent-class')
child = parent.find('p', class_='child-class')
print("Enfant spécifique:", child.text)
```

4. Données Structurées

Exemple 17 : Extraire un tableau HTML

url "https ://www.w3schools.com/html/html_tables.asp"

```
table = soup.find('table')
for row in table.find_all('tr'):
    cells = row.find_all('td')
    if cells:
        print("Ligne:", [cell.text for cell in cells])
```

Exemple 18 : Liste à puces

```
ul = soup.find('ul')
for li in ul.find_all('li'):
    print("Élément liste:", li.text)
```

5. Exemple Complet : Scraper des Livres

```
base_url = "http://books.toscrape.com/"
page = requests.get(base_url)
soup = BeautifulSoup(page.text, 'html.parser')

for book in soup.find_all('article', class_='product_pod'):
    title = book.h3.a['title']
    price = book.find('p', class_='price_color').text
    print(f"Livre: {title} | Prix: {price}")
```

Exemple 19 : Extraire des éléments d'un formulaire

```
form = soup.find('form')
inputs = form.find_all('input')
for input_tag in inputs:
    print("Nom de champ:", input_tag.get('name'))
```

Exemple 20 : Récupérer des informations sur un lien spécifique (balise <a>)

```
specific_link = soup.find('a', href='/some-link')
print("Texte du lien:", specific_link.text)
```

6. Exercices Pratiques

- **Exercice 1** : Scraper tous les titres et prix des livres sur `http://books.toscrape.com/`
- **Exercice 2** : Extraire tous les liens d'images (balises `<img>`) d'une page
- **Exercice 3** : Créer un scraper qui compte le nombre de paragraphes sur une page
- **Exercice 4** : Extraire les métadonnées (balises `<meta>`) d'une page
- **Exercice 5** : Extraire les titres des livres avec un prix inférieur à 30£
- **Exercice 6** : Extraire les balises `<h1>` à `<h3>` d'une page et afficher leur contenu

— **Exercice 7** : Scraper les noms de catégories depuis le menu latéral du site `http://books.toscrape.com/`
— **Exercice 8** : Extraire le nombre d'étoiles (note) pour chaque livre

7. Conseils Importants

1. Utiliser `time.sleep(1)` entre les requêtes
2. Gérer les erreurs avec `try/except`
3. Inspecter le code HTML de la page (clic droit → Inspecter ou Ctrl+U)

8. Solutions des Exercices

Solution Exercice 1

```
for book in soup.find_all('article', class_='product_pod'):
    print(book.h3.a['title'], "-", book.find('p', class_='price_color
        ').text)
```

Solution Exercice 2

```
for img in soup.find_all('img'):
    print(img['src'])
```

Solution Exercice 3

```
print("Nombre de paragraphes:", len(soup.find_all('p')))
```

Solution Exercice 4

```
for meta in soup.find_all('meta'):
    print(meta)
```

Solution Exercice 5

```
for book in soup.find_all('article', class_='product_pod'):
    price = book.find('p', class_='price_color').text
    price_value = float(price[1:])  # Enlève le symbole č
    if price_value < 30:
        print(book.h3.a['title'], "-", price)
```

Solution Exercice 6

```
for tag in ['h1', 'h2', 'h3']:
    for elem in soup.find_all(tag):
        print(f"{tag.upper()}:", elem.text.strip())
```

Solution Exercice 7

```
categories = soup.select('.side_categories ul li ul li a')
for category in categories:
    print(category.text.strip())
```

Solution Exercice 8

```
for book in soup.find_all('article', class_='product_pod'):
    stars = book.find('p')['class']
    if 'star-rating' in stars:
        rating = stars[1]
        print(book.h3.a['title'], "-", rating)
```

Devoir a Rendre :

Scraper le site Books to Scrape pour extraire des informations sur les livres et les enregistrer dans un fichier CSV structuré.

1. Collecte des données

- Accéder au catalogue de livres
- Extraire pour chaque livre :
  - Titre
  - Prix
  - Note (rating)
  - Disponibilité (stock)
  - Lien vers l'image de couverture

2. Gestion de la pagination

- Le site contient 50 pages
- Le script doit parcourir toutes les pages automatiquement

3. Export des données

- Format : `books.csv`
- En-tête :
  `Title,Price,Rating,Stock,Image_URL`

4. Bonus (optionnel)

- Télécharger les images dans un dossier `/images`
- Gérer les erreurs (pages inaccessibles, éléments manquants)

Contraintes techniques

- Utiliser Python avec :
  - `requests` et `BeautifulSoup`
  - `pandas` ou `csv` pour l'export
- Code lisible et commenté

Livrables attendus

— Script Python `scrape_books.py`
— Fichier CSV `books.csv`
— (Bonus) Dossier `/images`

Exemple de sortie CSV

```
Title,Price,Rating,Stock,Image_URL
"A Light in the Attic",č51.77,3,In stock,"http://..."
"Tipping the Velvet",č53.74,1,In stock,"http://..."
...
```